Shazam da natureza: identificando animais por sons

Palestrante: Ítalo Epifânio de Lima e Silva

Programa de Pós-Graduação em Ciências de Computação e Matemática Computacional
Instituto de Ciências Matemáticas e de Computação (ICMC)
Universidade de São Paulo

17/10/2026

Quem sou eu

- Norte-rio-grandense (da trombinha do elefante)
- Cientista da Computação (UFRN)
- Mestrando em Ciências da Computação (USP)
- AI/ML Platform Engineer na Shape Digital



Sumário

1 Shazam da natureza

2 Bioacústica

3 Modelando um Shazam

4 Conclusão

Usuário

- Biólogos
- Ecológos



Figura 1: Vitória Maria Moreira configurando AudioMoth

Qual dor esse Shazam resolve?

- Monitorar ecossistemas através do som
  - Classificar quais espécies estão disponíveis em locais de difícil acesso
  - Contar quantos animais ali estão
  - Entender tipos de vocalização e hábitos de determinadas espécies
- Classificar e segmentar longos áudios para entender um ecossistema
- Biólogos e Ecológos são clientes, mas também são desenvolvedores!

Ecologia da paisagem acústica

- **Paisagem acústica (Soundscape):** relação entre uma paisagem geográfica e a composição de seus sons integrados
- **Ecologia da paisagem acústica (Soundscape Ecology):** investigação das interações estruturais entre três matrizes sonoras (PIJANOWSKI et al., 2011)
  - **Biofonia:** sons de origem biológica (vocalizações, chamados)
  - **Geofonia:** sons abióticos naturais (vento, chuva, trovões)
  - **Antropofonia:** sons gerados por atividades e dispositivos humanos

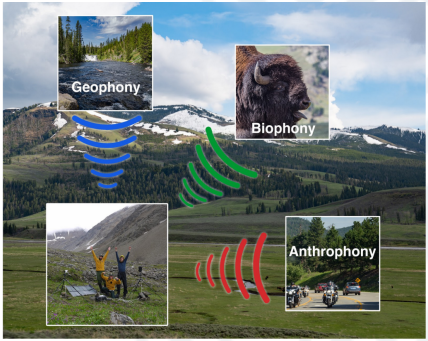


Figura 2: Ilustração do *framework* conceitual de Soundscape Ecology (SEKTON; SKWARCAN, 2020)

Bioacústica

- Foca na comunicação animal: comportamento, teória das histórias de vida e física da produção do som
- Monitoramento de espécies com hábitos noturnos
- Monitorar espécies em habitat de difícil acesso
  - Pântanos
  - Florestas densas
  - Recifes de corais

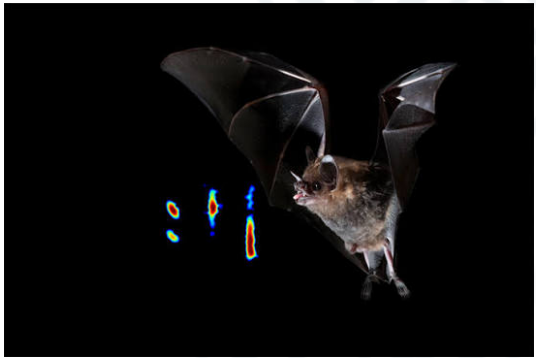


Figura 3: Vocalização de Morcego, uma das primeiras espécies de interesse da bioacústica

Shazam e classificação de vocalização animal

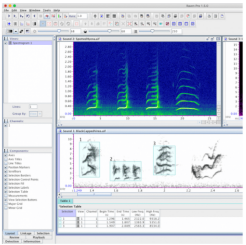
A classificação uma das tarefas que fazem parte da pesquisa em bioacústica.

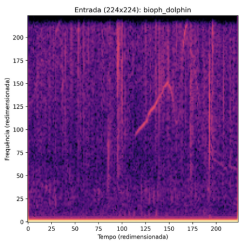
- Áudios longos, com baixo *signal-to-noise ratio*
- Muita interferência de vento, chuva e ações humanas
- Quantidade de dados supera a capacidade humana de investigação
- Dados são desbalanceados devidos a espécie de interesse estarem comumente ameaçados de extinção

Fluxo de processamento em classificação de vocalização animal

1. **Aquisição de dados:** amostragem em campo via sensores.







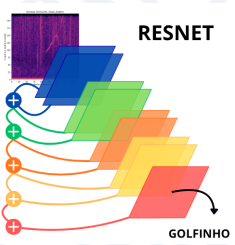
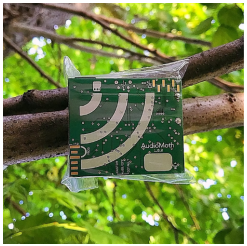
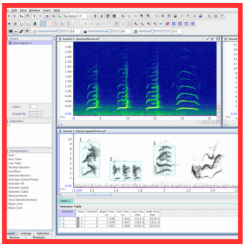


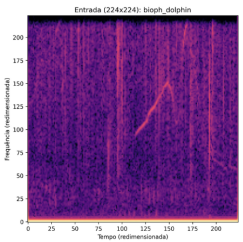
Figura 4: Fluxo CSA com destaque para o sensor em campo

Fluxo de processamento em classificação de vocalização animal

2. Pré-processamento: filtragem, segmentação e análise do espectrograma.







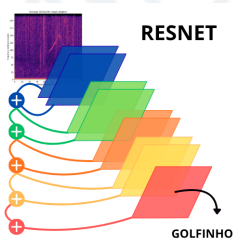
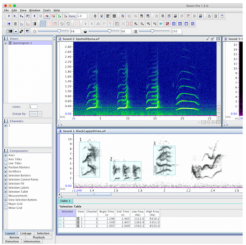


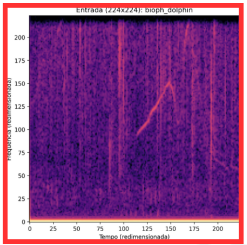
Figura 5: Fluxo CSA com destaque para o programa Raven Pro e seu processo de anotação

Fluxo de processamento em classificação de vocalização animal

3. Extração de características (*feature extraction*): interface entre o áudio e o processamento da máquina.







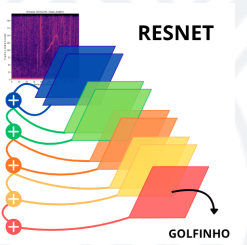


Figura 6: Fluxo CSA com destaque para o espectrograma

Fluxo de processamento em classificação de vocalização animal

4. **Classificação:** inferência de categorias discretas via modelos preditivos.

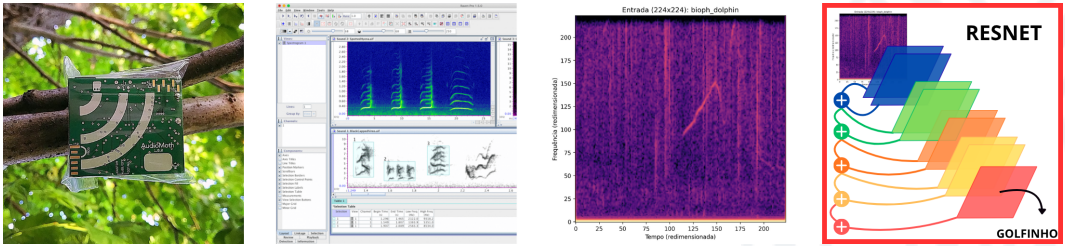


Figura 7: Fluxo CSA com destaque para uma ilustração de modelo preditivo ResNet

Democratização

Estado da arte dominado por aprendizado profundo com foco em CNNs (KERSHENBAUM et al., 2025), (XIE et al., 2025)



(a) *Kitzes Lab:* laboratório da Universidade de Pittsburgh, responsável pelo OpenSoundscape e AudioMoth



(b) *Deep Voice:* organização responsável pelo SoundBay



(c) VocalPy: organização responsável pelo Vak, Crowsetta e VocalPy

Figura 8: Organizações com soluções *open source* voltadas ao treinamento de modelos de aprendizado de máquina

Aquisição de dados

- Dispositivos de gravação autônomos
- Configuração da frequência das vocalizações de interesse e ciclo de gravação
- Após recuperar o dispositivo os sons são comumente convertidos em formato wav



Figura 9: A esquerda AudioMoth e a direita Wildlife

Pré-processamento

- Segmentar e transformar o arquivo *wav* em um espectrograma ou mel-spectrograma

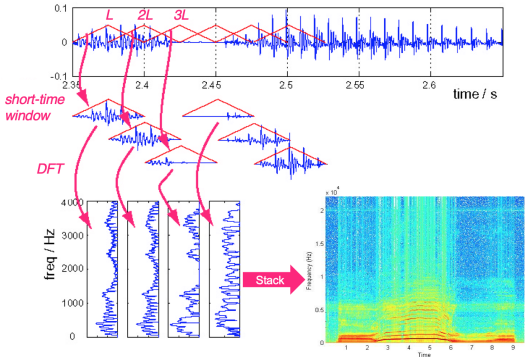


Figura 10: Processo de conversão do áudio para espectrograma

Pré-processamento

- Transformada de Fourier e a decomposição de um sinal nas frequências que o compõe



Figura 11:
https://www.youtube.com/watch?v=spUNpyF58BY

Pré-processamento

- Espectrograma comum vs Espetrograma Mel
- Existem outras *features* como PCEN e MFCC

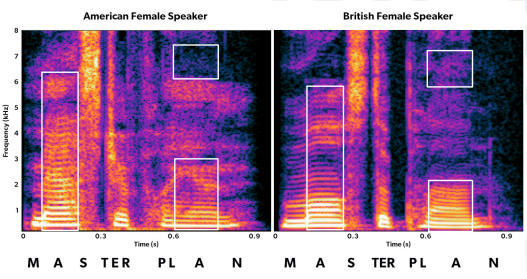


Figura 12: Comparação de vocalização humana entre pronúncia estadunidense e inglesa

Pré-processamento

- O tipo de entrada é importante para o modelo que está sendo desenvolvido (WIERUCKA et al., 2025)



Figura 13: https://poloclub.github.io/cnn-explainer

Pré-processamento

- Analise e anotação de dados é um processo caro e demorado, mas necessário

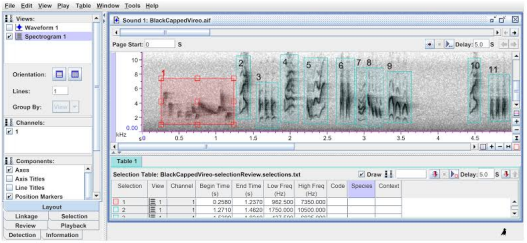


Figura 14: Ilustração do Raven Pro

Classificação de vocalização animal

- Aprendizado por transferência (*Transfer Learning*)
- Ajuste fino (*Fine-tuning*)

Classificação de vocalização animal

Tabela 1: Modelos fundacionais da bioacústica

Modelo	Descrição
BirdNet (KAHL et al., 2021)	ResNet de 157 camadas, com mais de 27 milhões de parâmetros e focado em identificar diversidade aviária. Conta com quase 1.000 classes, contidas em 3.978 horas de áudio, foram utilizadas para o seu treinamento.
Perch (GHANI et al., 2023)	Usa uma arquitetura EfficientNet B1, com mais de 7.8 milhões de parâmetros, focado em identificar diversidade aviária. Treinado exclusivamente com vocalizações de mais de 10.000 espécies de aves e milhares de horas de áudio.
Perch 2.0 (MERRIËNBOER et al., 2025)	Usa uma arquitetura EfficientNet B3, com mais de 12 milhões de parâmetros, focado em identificar diversidade aviária. Essa versão não se restringe apenas a espécies de aves, totalizando 14.597 classes de vocalizações animais e 198 classes de eventos sonoros gerais.
SurfPerch (WILLIAMS et al., 2025)	Extensão do Perch por meio de aprendizado de transferência, treinada especificamente para o monitoramento de recifes de corais e mamíferos marinhos. O conjunto adicional de dados utilizado, ReefSet, contém 37 classes.

Minha pesquisa

Como a geração sintética de amostras contribui para a classificação de vocalização animal?

- Áudio
- Espectrograma

Minha pesquisa

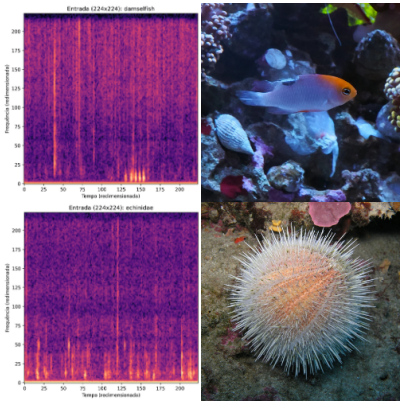


Figura 15: Vocalizações *damselfish* e *echinidae*

Figura 16:
https://artsandculture.google.com/experiment/calling-in-our-corals/zgFx1tMqeIZyTw

Minha pesquisa

- ReefSet
- AnuraSet
- Watkins Marine Mammal Sound Database
- Xeno-Canto
- Marmoset Vocalizations
- Audio tagging of avian dawn chorus recordings

Coisas legais que aprendi até agora

- Modelos que funcionam na gringa não funcionam bem aqui: biodiversidade muito maior (*signal-to-noise ratio* e *chorus*)
- Peixes fazem sons! (e temos microfones especiais para detectar eles
- O estado da arte de Shazam da Natureza usa modelos de visão computacional e não de som

Coisas legais que aprendi até agora

- *The devil is in the tails*
  - Focal loss vs Balanced Loss
  - *oversampling* vs *undersampling*
  - Calibração de modelo

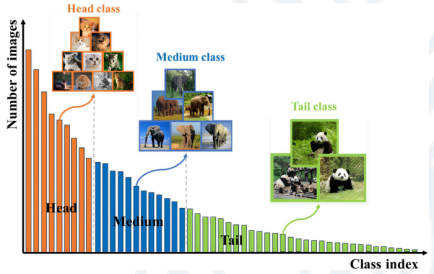


Figura 17: Exemplo de conjunto de dados com "cauda longa"

Coisas legais que aprendi até agora

- Estima-se que recifes de corais contém certa de 25% de todas as espécies marinhas
- Monitorar eles ajuda a entender se estratégias de conservação estão dando certo
- O melhor programa de conservação é a eleição de representantes que enfrentem diretamente a crise climática

Material suplementar



Figura 18: https://github.com/itepifanio/shazam-da-natureza

OBRIGADO



Figura 19:
https://www.linkedin.com/in/italoepifanio

References I

GHANI, B. et al. Global birdsong embeddings enable superior transfer learning for bioacoustic classification. *Scientific Reports*, Nature Publishing Group UK London, v. 13, n. 1, p. 22876, 2023.

KAHL, S. et al. Birdnet: A deep learning solution for avian diversity monitoring. *Ecological Informatics*, Elsevier, v. 61, p. 101236, 2021.

KERSHENBAUM, A. et al. Automatic detection for bioacoustic research: a practical guide from and for biologists and computer scientists. *Biological Reviews*, Wiley Online Library, v. 100, n. 2, p. 620–646, 2025.

MERRIËNBOER, B. van et al. Perch 2.0: The bittern lesson for bioacoustics. *arXiv preprint arXiv:2508.04665*, 2025.

PIJANOWSKI, B. C. et al. Soundscape ecology: the science of sound in the landscape. *BioScience*, American Institute of Biological Sciences Circulation, AIBS, 1313 Dolley ..., v. 61, n. 3, p. 203–216, 2011.

References II

SEKTON, N.; SKWARCAN, S. *At the intersection of Art, Science, and community*. The University of Texas at Austin, 2020. Disponível em: <https://www.jsg.utexas.edu/science-yall/at-the-intersection-of-art-science-and-community/>.

WIERUCKA, K. et al. Same data, different results? machine learning approaches in bioacoustics. *Methods in Ecology and Evolution*, v. 16, n. 8, p. 1574–1586, 2025. Disponível em: <https://besjournals.onlinelibrary.wiley.com/doi/abs/10.1111/2041-210X.70091>.

WILLIAMS, B. et al. Using tropical reef, bird and unrelated sounds for superior transfer learning in marine bioacoustics. *Philosophical Transactions B*, The Royal Society, v. 380, n. 1928, p. 20240280, 2025.

XIE, J. et al. Decoding nature's melody: significance and challenges of machine learning in assessing bird diversity via soundscape analysis. *Artificial Intelligence Review*, Springer, v. 59, n. 1, p. 10, 2025.